



華東師範大學

EAST CHINA NORMAL UNIVERSITY

数据科学与工程算法基础

Algorithm Foundations of Data Science and Engineering

第九章 SVD 与 PCA

$$(1+x)^n = 1 + \frac{nx}{1!} + \frac{n(n-1)x^2}{2!} + \dots$$

课程提纲

Content

1 算法引入

2 SVD

3 PCA

课程提纲

Content

1 算法引入

2 SVD

3 PCA

矩阵对角化

- 特征空间维度为 n 的矩阵 $A \in \mathbb{R}^{n \times n}$ 可以正交对角化，即 $A = P\Sigma P^\top$

- P 为正交矩阵
- Σ 为对角矩阵

- 很多应用中矩阵并非方阵

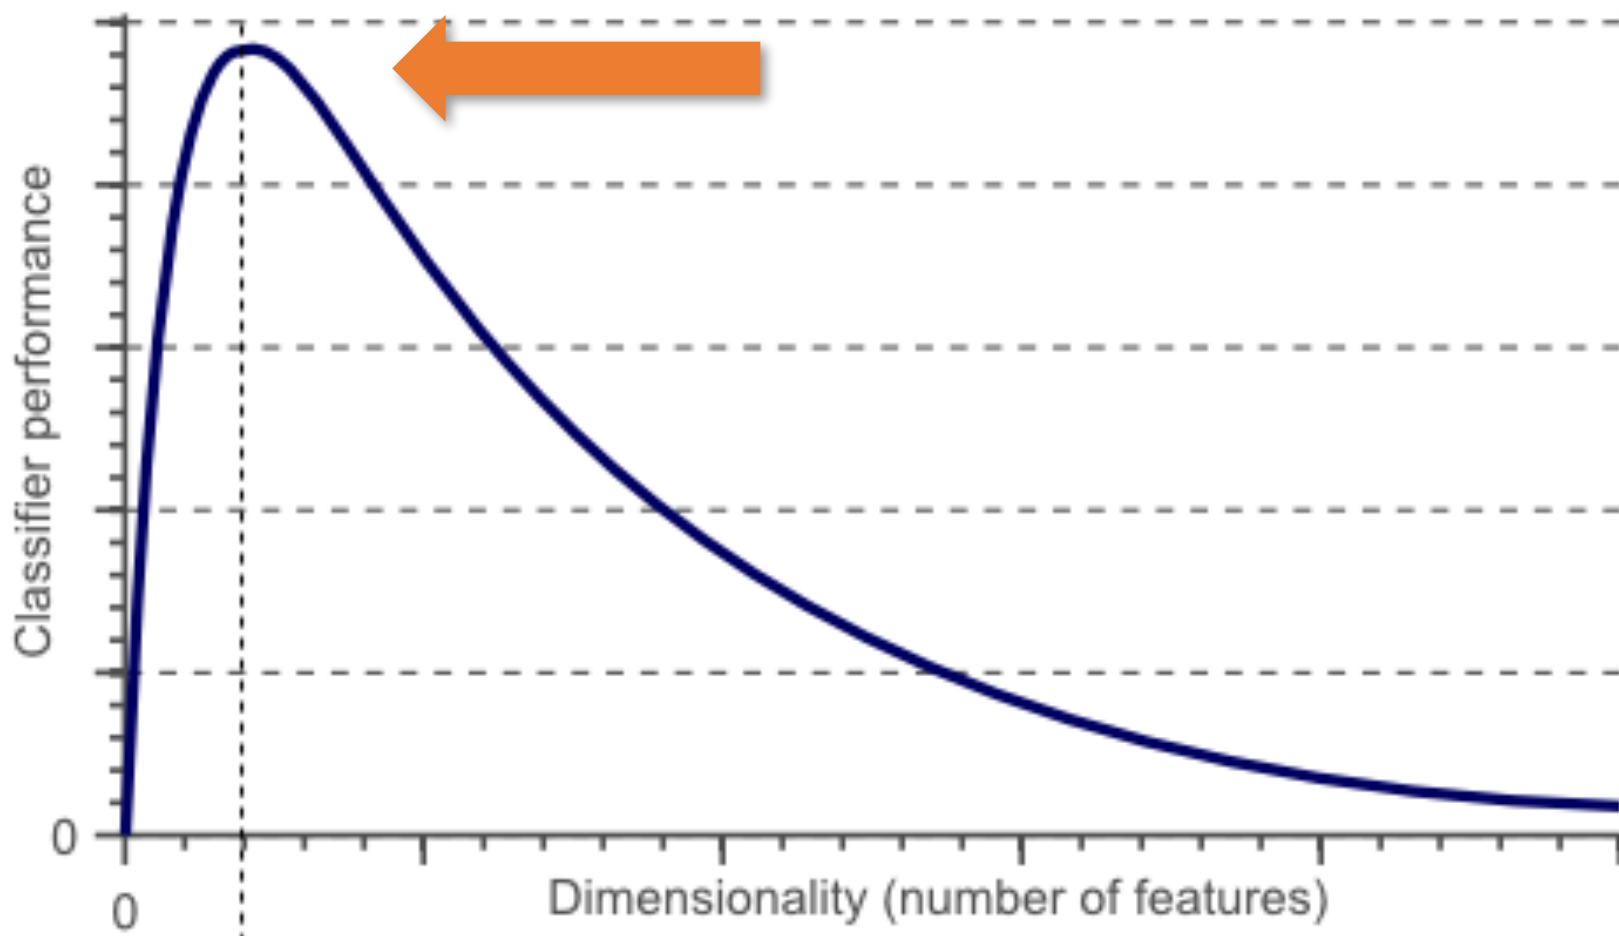
- 二分图邻接矩阵
- 特征矩阵
- 图像
-

$$A = \begin{pmatrix} a_{11} & \dots & a_{1j} & a_{1N} \\ \dots & & & \dots \\ a_{i1} & & a_{ij} & a_{iN} \\ \dots & & & \dots \\ a_{M1} & \dots & a_{Mj} & a_{MN} \end{pmatrix}$$

- 不是方阵可以对角化吗？

降维

- 随着维数的增加，分类器的性能会先增后降



图片压缩



- 无人机性能参数
 - 速度100–300 m/s
 - 视频帧率为25–30 帧/s
 - 帧与帧间有重叠
- 航拍图像相关性非常强
- 如何利用相关性降低图像存储与传输量
- 图像压缩旨在解决这一问题
 - 无损压缩
 - 有损压缩



课程提纲

Content

1 算法引入

2 SVD

3 PCA

相似矩阵

- 对于矩阵 $A, B \in \mathbb{R}^{n \times n}$ ，如果存在一个可逆的 $n \times n$ 矩阵 P ，使得 $A = PBP^{-1}$ ，则称它们为相似矩阵
- **定理：** 若两个 $n \times n$ 矩阵相似，则它们有相同的特征多项式，而且相同特征值的重数也相同
 - 方阵 A 可对角化：相似于一个对角矩阵，即存在一个可逆矩阵 P ，使得 $A = PDP^{-1}$ ，其中 D 为对角矩阵
 - 如果 A 是可对角化的，那么 $A^k = PD^kP^{-1}$ ， $k > 0$
 - 矩阵相似是一种等价关系：自反性、对称性和传递性
- 如果 v_1, \dots, v_n 是矩阵 A 的线性无关的特征向量， λ_i 是 v_i 对应的特征值，那么 $A = PDP^{-1}$ ，其中 $P = [v_1 \dots v_n]$ 且 $D = \text{Diag}(\lambda_1, \dots, \lambda_n)$

对角化条件



- 矩阵 $A \in \mathbb{R}^{n \times n}$ 可对角化当且仅当 A 的每个特征值的几何重数都等于其代数重数
 - 矩阵 $A \in \mathbb{R}^{n \times n}$ 有 n 个不重复的特征值时可对角化
 - 例如 $A = \begin{pmatrix} 2 & 4 & 6 \\ 0 & 2 & 2 \\ 0 & 0 & 4 \end{pmatrix}$ 的特征值为 $\lambda_1 = \lambda_2 = 2$, $\lambda_3 = 4$
 - $\lambda_1 = \lambda_2 = 2$ 对应的特征向量为 $(1, 0, 0)^T$, 解 $(A - 2I)v = 0$ 可得
 - 代数重数 \neq 几何重数
 - 因此, 矩阵 A 不可对角化

实对称矩阵的对角化



- 如果 $P^{-1} = P^{\top}$ ，方阵 P 是正交矩阵
- 矩阵 A 可正交对角化，如果存在方阵 P 使得 $A = PDP^{\top}$ ，其中 D 为对角矩阵
- 实对称矩阵的性质
 - A 有 n 个特征值（包括重数）
 - 对于任一特征值，其对应的特征向量的几何重数等于代数重数
 - 如果 A 为实对称矩阵，那么 A 的任意两个特征向量都是正交的
 - 特征空间是相互正交的
 - A 是可正交对角化的

对角化的几何解释



$$\begin{pmatrix} 1.5 & 0.5 \\ 0.5 & 1.0 \end{pmatrix} = \begin{pmatrix} 0.85 & -0.53 \\ 0.53 & 0.85 \end{pmatrix} \begin{pmatrix} 1.81 & 0 \\ 0 & 0.69 \end{pmatrix} \begin{pmatrix} 0.85 & -0.53 \\ 0.53 & 0.85 \end{pmatrix}^T$$




$$\begin{bmatrix} 0.85 & 0.53 \\ -0.53 & 0.85 \end{bmatrix}$$



$$\begin{bmatrix} 1.81 & 0 \\ 0 & 0.69 \end{bmatrix}$$



$$\begin{bmatrix} 0.85 & -0.53 \\ 0.53 & 0.85 \end{bmatrix}$$




奇异值

- 对任意矩阵 A , AA^T 和 A^TA 都是对称半正定矩阵 (课后尝试自己证明)
 - 所有特征值非负; 可以正交对角化
- 对任意矩阵 A , 有 $\text{rank}(A) = \text{rank}(AA^T) = \text{rank}(A^TA)$
 - AA^T 和 A^TA 都有 $\text{rank}(A)$ 个非零特征值
- 实对称矩阵 AA^T 和 A^TA 的特征值分别为 λ_i 和 μ_i , 我们有 $\lambda_i = \mu_i > 0, i = 1, 2, \dots, r$ (课后尝试自己证明)
- 对 $A \in \mathbb{R}^{m \times n}$, AA^T 和 A^TA 的特征值分别为 λ_i 和 μ_i , 我们称 $\alpha_i = \sqrt{\lambda_i} = \sqrt{\mu_i}, i = 1, \dots, r$ 为 A 的奇异值

奇异值分解

- 奇异值分解 (Singular Value Decomposition, SVD)


- 任意 $m \times n$ 的矩阵 A 都可以被分解为 $A_{[m \times n]} \sim U_{[m \times m]} D_{[m \times n]} V_{[n \times n]}^T$



- 矩阵 A 为 $m \times n$ 的矩阵 (不一定为方阵)
 - ✓ 例如 m 个用户, n 个物品
 - ✓ U 和 V : 左 (m 个用户和 k 种兴趣) 和右奇异 (k 种兴趣和 n 个商品) 矩阵
 - ✓ D : 一个 $m \times n$ 的对角矩阵仅有 k 个非零分量

SVD 分解方法

- 假如 $A = UDV^T$ ，如何确定矩阵 U, D, V
 - 实对称矩阵 AA^T 的正交对角化 $AA^T = UD^2U^T$
 - 实对称矩阵 A^TA 的正交对角化 $A^TA = VD^2V^T$
 - 其中 $D^2 = \text{Diag}(\sigma_1^2, \dots, \sigma_k^2)$, $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > 0$ 称为矩阵 A 的奇异值



降维方法

$$A = [u_1 \cdots u_k | u_{k+1} \cdots u_m] \left[\begin{array}{ccc|ccc} \sigma_1 & & & & & \\ & \ddots & & & & \\ & & \sigma_k & & & \\ \hline & & & 0 & & \\ & & & & 0 & \\ & & & & & 0 \end{array} \right] \left[\begin{array}{c} v_1^T \\ \vdots \\ v_k^T \\ \hline v_{k+1}^T \\ \vdots \\ v_n^T \end{array} \right]$$


$$A \approx [u_1 \cdots u_k] \left[\begin{array}{ccc} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \end{array} \right] \left[\begin{array}{c} v_1^T \\ \vdots \\ v_k^T \end{array} \right]$$

一些小的奇异值可以
忽略不计

$$k = \arg \min_l \left\{ \frac{\sum_{i=1}^l \sigma_i}{\sum_{i=k}^l \sigma_i} > 90\% \right\} \text{ 个最大的奇异值重构的矩阵为 } A^{(k)} \approx \sum_{i=1}^k \sigma_i u_i v_i^\top$$

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} \approx \begin{bmatrix} 0.18 & 0 \\ 0.36 & 0 \\ 0.18 & 0 \\ 0.90 & 0 \\ 0 & 0.53 \\ 0 & 0.80 \\ 0 & 0.27 \end{bmatrix} \times \begin{bmatrix} 9.64 & 0 \\ 0 & 5.29 \end{bmatrix} \times \begin{bmatrix} 0.58 & 0.58 & 0.58 & 0 & 0 \\ 0 & 0 & 0 & 0.71 & 0.71 \end{bmatrix}$$

SVD 的几何解释



- SVD给出来最佳投影，“最佳”是指最小化总的投影误差SVD给出最小重构误差的降维方法

重构误差

- 矩阵 A 的2范数和Frobenius范数定义如下:

- $\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sigma_{\max}(A)$

- $\|A\|_F = \sqrt{\sum_{i,j} a_{i,j}^2} = \sqrt{\text{Trace}(A^T A)}$

- 如果 $r < k$, $A^{(r)} \approx \sum_{i=1}^r \sigma_i u_i v_i^T$

- 重构误差将为

- $\|A^{(r)} - A\|_2 = \sigma_{r+1}$

- $\|A^{(r)} - A\|_F = \sqrt{\sum_{i=r+1}^k \sigma_i^2}$

SVD 的应用

- 方阵 A 是非奇异的, 则对 $\forall i$ 都有 $\sigma_i > 0$
 - 如果 A 是非奇异矩阵, 它的逆矩阵为 $A^{-1} = V^T D^{-1} U$
 - 如果 A 是奇异矩阵, 可以用SVD来近似它的逆矩阵
 - $A^{-1} = (UDV^T)^{-1} \approx V^T D_0^{-1} U$, 其中 $D_0^{-1} = \begin{cases} \frac{1}{\sigma_i} & \text{if } \sigma_i > t \\ 0 & \text{otherwise} \end{cases}$, 其中 t 是一个阈值
- 其他应用
 - 数据压缩
 - 主成分分析
 - 个性化推荐 (协同过滤)

课程提纲

Content

1 算法引入


2 SVD

3 PCA

降维

$$X = \begin{bmatrix} a_1 \\ a_2 \\ \dots \\ a_N \end{bmatrix} \dashrightarrow \text{降维} \dashrightarrow y = \begin{bmatrix} b_1 \\ b_2 \\ \dots \\ b_K \end{bmatrix} \quad (K \ll N)$$

- 高维数据可能会出现问题，如维度灾难、过拟合
 - 将数据映射到低维空间
 - 但保留原数据中尽可能多的信息
- 降维的目标
 - 找到好的特征表示
 - 减少数据冗余



主成分分析

- 主成分分析 (PCA)
 - 删除数据间的冗余关系
 - 保留尽可能的信息
- PCA: SVD 方法的一个应用
 - 将数据投影到最佳低维空间, 其中“最佳”意味着投影误差最小
 - 即最小化重构误差
 - 根据高维数据的协方差矩阵确定最佳的投影方向
 - 协方差矩阵“最大”特征值对应的特征向量方向
 - 也称为“主成分”

协方差

- 样本均值 $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$
- 样本方差 $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$
- 对于两个维度X和Y，协方差定义为
$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$
 - X_i 和 Y_i 偏离 \bar{X} 和 \bar{Y} 同号：正相关
 - X_i 和 Y_i 偏离 \bar{X} 和 \bar{Y} 异号：负相关
 - X_i 和 Y_i 偏离 \bar{X} 和 \bar{Y} 正负没有明显特征：不相关

协方差矩阵

- 对于 n 维数据集，我们可以计算每个维度之间的协方差，共 $n \times n$ 个协方差
- 协方差矩阵 Σ ：实对称矩阵


$$\Sigma = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Cov}(X_n, X_n) \end{bmatrix}$$

PCA 方法

- 假设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 是 $d \times 1$ 维向量
 - 计算中心化向量 $\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$ 并去中心化 $\mathbf{y}_i = \mathbf{x}_i - \bar{\mathbf{x}}$
 - 构造 $d \times n$ 维矩阵 $Y = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n]$, 计算 $d \times d$ 维协方差矩阵 $C = \frac{YY^T}{n-1}$
 - 对 C 矩阵进行正交对角化（对 Y 矩阵进行 SVD 分解），假定 λ_i 对应的特征向量为 \mathbf{u}_i
 - 保留前 k 个大于 α 的特征值对应的特征向量
 - 降维重建向量 $\hat{\mathbf{x}}_i = [\mathbf{u}_1, \dots, \mathbf{u}_k]^T \mathbf{x}_i$

PCA 分析

- PCA 是 SVD 方法的一个应用，因此 PCA 方法最小化了重构误差
- PCA 并不总是最优的降维方法，如分类问题



本章小结

- SVD方法实现非方阵的对角化分解
 - 重构误差最小化
 - PCA是SVD方法的一个应用
- 高维数据处理
 - 高维数据在应用中随处可见
 - 文本，图像，图，.....
 - 降维是高维数据的常用处理方法
 - 线性降维方法
 - 非线性降维方法，如t-SNE